数据挖掘导论课程报告

1 全局分类与局部记忆融合的工业图像异常检测方法

工业图像异常检测以产品的正常外观为参照，识别表面缺损、结构变化及纹理偏离。整张图像的外观差异和少量位置的局部异常提供不同的判断依据，因此采用全局支持向量机与正常局部记忆库构成并行检测分支。两个分支共享冻结的卷积特征，分别计算整图分类分数和局部最近邻距离，再通过训练集内的分数校准与加权融合形成统一评分。

图1展示的是全局分类与局部记忆融合的图像异常检测框架。共享特征由预训练 Wide ResNet50-2 提取。全局分支将多层池化向量送入核分类器，局部分支将空间描述子与正常记忆库比较。训练阶段利用折外分数确定参数、校准统计量和阈值；预测阶段复用冻结配置，输出图像级正常或异常标签。

1.1 任务定义

设产品类别为 $c \in \{\text{榛子}, \text{拉链}\}$，其带标签训练集为

$$\mathcal{D}_c = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N_c}, \quad y_i \in \{0, 1\}, \tag{1}$$

其中 $\mathbf{x}_i$ 为 RGB 图像，$y_i = 0$ 表示正常，$y_i = 1$ 表示异常。学习目标是利用训练图像及其标签构造评分函数 S_c 和阈值 τ_c。对已知产品类别的待测图像 $\mathbf{x}$，判断规则为

$$\hat{y} = \mathbb{I}(S_c(\mathbf{x}) \geq \tau_c). \tag{2}$$

较大的分数表示更强的异常倾向。两个产品类别分别建立模型和阈值。训练集同时包含正常与异常图像，因此整体方法使用监督信息；其中局部记忆库仅由正常训练图像建立。

1.2 共享卷积特征与多尺度表示

图像解码为 RGB 后，将完整画面双线性缩放至 384×384。像素先映射至 $[0, 1]$，再使用 ImageNet 通道均值 $(0.485, 0.456, 0.406)$ 与标准差 $(0.229, 0.224, 0.225)$ 进行标准化。该过程保留完整的榛壳与拉链布边，训练、验证和测试使用相同变换。

特征提取器采用 Wide ResNet50-2 的 ImageNet-1K V1 权重[4,5]。固定网络参数，并在评估模式下使用预训练的批归一化统计量。记 `layer2`、`layer3` 和 `layer4` 输出为 $\mathbf{F}_2, \mathbf{F}_3, \mathbf{F}_4$，其通道数分别为 512、1024 和 2048，空间网格分别为 48×48、24×24 和 12×12。

全局表示汇总各层的空间均值与最大响应。记 GAP 和 GMP 为对应池化算子，则

$$\begin{aligned} \mathbf{g}(\mathbf{x}) &= \operatorname*{Concat}_{\ell \in \{2,3,4\}} \big[\mathrm{GAP}(\mathbf{F}_\ell), \mathrm{GMP}(\mathbf{F}_\ell)\big], \\ \mathbf{g}(\mathbf{x}) &\in \mathbb{R}^{7168}. \end{aligned} \tag{3}$$

其中 $7168 = 2(512 + 1024 + 2048)$。均值池化描述整体响应，最大池化保留较突出的位置，二者共同形成整图表示。

局部表示保留空间对应关系。对 $\mathbf{F}_2$ 和 $\mathbf{F}_3$ 施加 3×3、步长为 1 的均值池化，并将后者双线性插值至 48×48。记位置 p 处拼接的 1536 维向量为 $\mathbf{v}_p$，固定随机投影为

$$\mathbf{z}_p = \mathbf{v}_p \mathbf{R}, \quad R_{ab} \sim \mathcal{N}(0, 1/256), \quad \mathbf{z}_p \in \mathbb{R}^{256}. \tag{4}$$

矩阵 $\mathbf{R} \in \mathbb{R}^{1536 \times 256}$ 使用种子 2026 生成，所有图像复用同一矩阵。每张图像得到 $48^2 = 2304$ 个局部描述子。随机投影减小后续距离计算的维度，而空间网格用于回查高响应位置。

每类仅有 250 张训练图像，冻结预训练网络将拟合集中在分类器与正常参照上，减少从小规模数据学习大量卷积参数的需求。全局池化提供紧凑的整图表示，但可能弱化小面积缺陷；局部网格保留细节，却也会响应正常纹理变化。设置两个分支是为了同时利用这两类证据。

1.3 全局支持向量机分支

对当前拟合集的全局特征逐维估计均值 μ_j 与标准差 σ_j，得到

$$u_j = \frac{g_j - \mu_j}{\sigma_j}, \quad \mathbf{u} \in \mathbb{R}^{7168}. \tag{5}$$

零方差维度的缩放因子取 1。验证和测试图像复用拟合阶段的统计量，避免使用待测样本重新估计特征尺度。

使用径向基核支持向量机学习正常与异常之间的边界[3]。核函数为

$$K(\mathbf{u}_i, \mathbf{u}_j) = \exp\big(-\gamma \|\mathbf{u}_i - \mathbf{u}_j\|_2^2\big). \tag{6}$$

令 $t_i = 2y_i - 1$，带类别权重的软间隔目标为

$$\begin{aligned} \min_{\mathbf{w}, b, \boldsymbol{\xi}} \quad & \frac{1}{2}\|\mathbf{w}\|_2^2 + C \sum_i a_{y_i} \xi_i, \\ \text{s.t.} \quad & t_i\big(\mathbf{w}^\top \phi(\mathbf{u}_i) + b\big) \geq 1 - \xi_i, \\ & \xi_i \geq 0, \end{aligned} \tag{7}$$

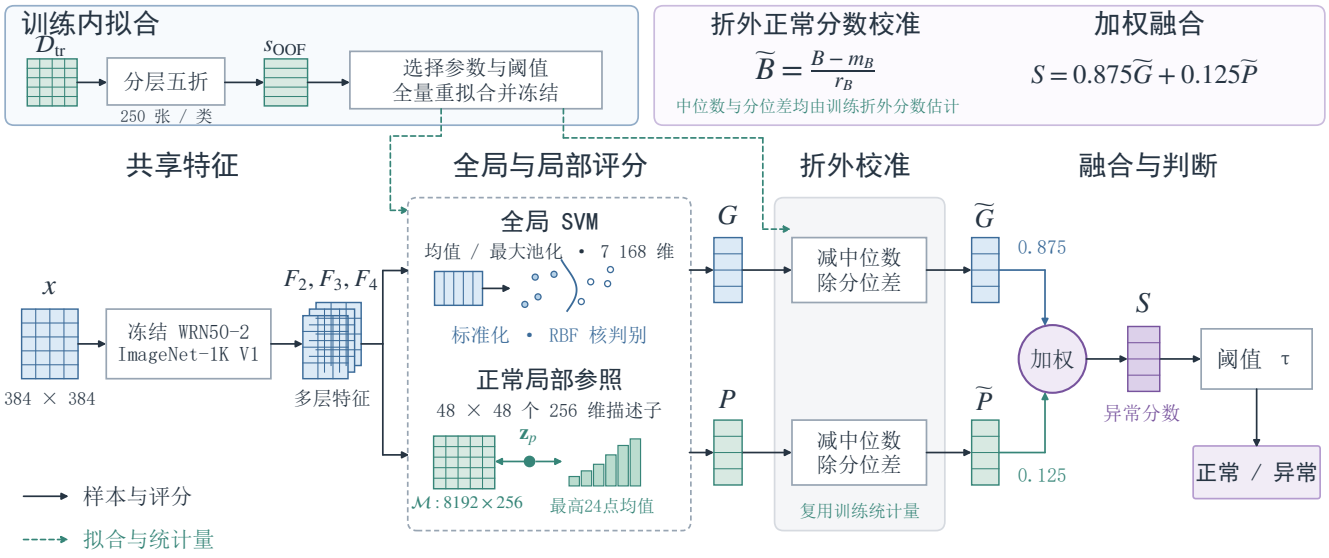


图 1: 全局分类与局部记忆融合的工业图像异常检测框架。m_B, r_B 分别为式(11)中的分数中心与尺度。

其中 $a_k = n/(2n_k)$，n_k 是拟合集内类别 k 的样本数。类别权重补偿正常与异常样本的数量差异。由支持向量及其系数得到全局分数

$$G(\mathbf{x}) = \sum_{i \in \mathcal{V}} \beta_i t_i K(\mathbf{u}_i, \mathbf{u}(\mathbf{x})) + b. \tag{8}$$

$\mathcal{V}$ 为支持向量索引集合。较大的 G 表示更接近训练异常样本一侧。

1.4 正常局部记忆与最近邻分支

局部分支利用正常图像的局部表示建立参照。该思路借鉴 PatchCore 的正常局部特征记忆[1]，具体实现采用随机无放回采样，不使用其贪心核心集选择。对当前拟合集中的正常图像，从全部局部描述子中抽取 8192 个组成记忆库 $\mathcal{M}_c$。

对待测图像位置 p，计算其到正常记忆库的最近欧氏距离

$$d_p(\mathbf{x}) = \min_{\mathbf{m} \in \mathcal{M}_c} \|\mathbf{z}_p(\mathbf{x}) - \mathbf{m}\|_2. \tag{9}$$

将 2304 个距离从大到小记为 $d_{(1)} \geq \cdots \geq d_{(2304)}$，局部分数为最高 k 个距离的均值：

$$P_q(\mathbf{x}) = \frac{1}{k} \sum_{r=1}^{k} d_{(r)}(\mathbf{x}), \quad k = \lceil 2304q \rceil. \tag{10}$$

该聚合保留少量位置上的高异常响应，并减轻单个极值的影响。每个记忆库保存 8192×256 个 `float32` 数值，占 8 MiB。精确最近邻计算按 256 个查询描述子分块执行，以限制中间距离矩阵的内存开销。

1.5 折外校准与加权融合

两个分支的数值范围不同，融合前使用训练集折外分数校准尺度。每个产品类别采用分层五折，保证一张训练图像的折外分数由未使用该图像拟合的模型给出。各折的特征标准化统计量与正常记忆库仅在当前拟合折建立。

对选定分支 $B \in \{G, P\}$，取正常训练图像的折外分数，记其第 10、50 和 90 百分位数为 Q_{10}^B、Q_{50}^B 和 Q_{90}^B。定义

$$\widetilde{B}(\mathbf{x}) = \frac{B(\mathbf{x}) - Q_{50}^B}{\max(Q_{90}^B - Q_{10}^B, 10^{-8})}. \tag{11}$$

中位数用于对齐正常分数中心，分位数跨度用于统一尺度。校准分数可以小于 0 或大于 1，不解释为异常概率。

给定局部分支权重 α，融合分数为

$$S_c(\mathbf{x}) = (1 - \alpha)\widetilde{G}(\mathbf{x}) + \alpha \widetilde{P}(\mathbf{x}). \tag{12}$$

先分别选择全局分支与局部分支的参数，再在选定分支的折外分数上选择 α。每组候选分数的阈值取相邻不同分数的中点及两端候选，以 F1 为首要目标；并列时依次比较平衡准确率、召回率，最后取较低阈值。参数候选按 F1、平衡准确率和 AUROC 依次比较。

确定配置后，使用每类全部训练图像重拟合 SVM 与正常记忆库，并保留折外校准统计量及阈值。测试阶段先保存冻结配置，再计算并保存图像分数和预测，最后与官方标签关联以计算指标。五折结果用于参数选择与校准，不作为独立的泛化性能估计。

表 1: 课程图像数据划分与类别构成（张）

	训练集		测试集		
产品	正常	异常	正常	异常	合计
榛子	200	50	40	15	305
拉链	200	50	32	15	297
合计	400	100	72	30	602

1.6 实验

1.6.1 数据预处理与划分. 实验使用课程任务提供的工业图像异常检测数据，包含榛子（hazelnut）与拉链（zipper）两个产品类别，共 602 张图像。表1展示了数据划分及类别构成。两类各使用 200 张正常图和 50 张异常图进行训练，测试集共有 72 张正常图和 30 张异常图。

程序直接读取课程压缩包，训练标签由 train/good 和 train/bad 目录确定，测试真值按产品类别与相对路径关联官方标签文件。核对原始数据可知，602 张图像的尺寸均为 1024×1024；解码为 RGB 后的像素哈希均不同，未发现像素完全相同的重复图像。

图2展示的是训练集中的正常与异常图像。榛子异常图 003 的壳面可见孔洞，拉链异常图 006 的布边出现缺损。这些差异可能仅占图像的一小部分，因此采用整图表示与局部表示共同评分。图3展示同一榛子图像的多层特征响应。随网络层次加深，空间网格逐步变粗，不同层提供不同尺度的外观线索。

1.6.2 实验配置与拟合流程. 每类训练集进行五折划分，每折使用 160 张正常图和 40 张异常图拟合，对另 40 张正常图与 10 张异常图计算折外分数。表2给出候选参数与最终配置。每类依次评估 4 组 SVM 参数、3 个局部聚合比例和 5 个融合权重，共 12 组候选；两类合计 24 组。该过程为分阶段选择，并非所有参数的笛卡尔积联合搜索。

实验在 Windows 11、Python 3.12.14、CPU 环境下重新执行，使用 PyTorch 2.10.0+cpu、Torchvision 0.25.0+cpu 及 scikit-learn 1.8.0，设置 4 个计算线程、每批 8 张图像。从原始图像提取特征、进行五折选参、全量重拟合及测试评价共耗时 5.96 分钟。下文表格由本次运行保存的预测和指标文件生成，图表使用同一份完整精度结果。

1.6.3 评价指标. 评价将异常图像作为正类。记真正例、真负例、假正例和假负例数分别为 TP、TN、FP 和 FN，总样本数为 N。固定阈值下的指标定义为

$$\begin{aligned} \mathrm{Accuracy} &= \frac{\mathrm{TP}+\mathrm{TN}}{N}, \\ \mathrm{Precision} &= \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}}, \quad \mathrm{Recall} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}}, \\ F1 &= \frac{2\mathrm{TP}}{2\mathrm{TP}+\mathrm{FP}+\mathrm{FN}}. \end{aligned} \tag{13}$$

准确率描述全部图像的正确比例，精确率描述异常预测中的真实异常比例，召回率描述异常图像的检出比例。F1 综合精确率与召回率，没有预测异常时将精确率与 F1 记为 0。

平衡准确率对两类正确识别率赋予相同权重：

$$\mathrm{BA} = \frac{1}{2}\left(\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}} + \frac{\mathrm{TN}}{\mathrm{TN}+\mathrm{FP}}\right). \tag{14}$$

连续分数使用 AUROC 和平均精确率（AP）评价排序质量；在类别比例不均衡时，PR 曲线有助于观察异常预测的精确率与召回率[2]。设正类、负类索引集合分别为 $\mathcal{P}$ 和 $\mathcal{N}$，对应样本数为 n_+ 与 n_-，则

$$\begin{aligned} \mathrm{AUROC} = \frac{1}{n_+ n_-} \sum_{i\in\mathcal{P}} \sum_{j\in\mathcal{N}} \big[&\mathbb{I}(S_i > S_j) \\ &+ \tfrac{1}{2}\mathbb{I}(S_i = S_j)\big]. \end{aligned} \tag{15}$$

同分样本对按半次正确排序计。AP 按召回率增量对精确率加权：

$$\mathrm{AP} = \sum_{\ell} (R_\ell - R_{\ell-1}) P_\ell, \quad R_0 = 0. \tag{16}$$

其中 P_ℓ, R_ℓ 对应阈值逐渐降低时的工作点，同分图像同时纳入。AP 采用阶梯加权，不使用梯形面积近似。由于两个产品独立建模，AUROC 与 AP 按产品报告；总体分类指标由各产品采用自身阈值后的混淆计数汇总计算。

1.6.4 总体效果与独立分支对照. 表3展示恒判正常、全局 SVM、局部最近邻和融合方法的测试集结果。各检测分支采用训练阶段确定的阈值。融合方法正确判断榛子 55/55 张、拉链 47/47 张，合计 102/102 张，72 张正常图与 30 张异常图均正确分类。

全局 SVM 与局部最近邻均正确判断 100/102 张，总体准确率为 98.04%；融合后提高至 100%，增加 1.96 个百分点。榛子融合结果与局部分支持平；拉链融合相较全局和局部分支分别多正确判断 1 张和 2 张，F1 分别提高 0.0323 和 0.0625。

恒判正常基线的总体准确率仍达到 $72/102 = 70.59\%$，但漏掉全部 30 张异常，召回率和 F1 均为 0，BA 为 0.5。因此，准确率应与异常召回率、误报数及漏检数共同解读。

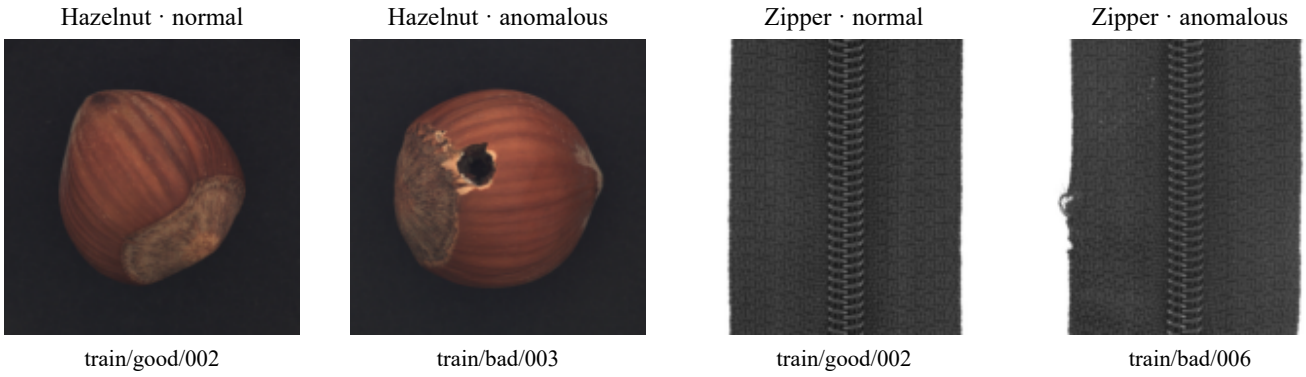


图 2: 课程训练集的正常与异常样例。编号对应产品类别及训练标签目录内的文件名。

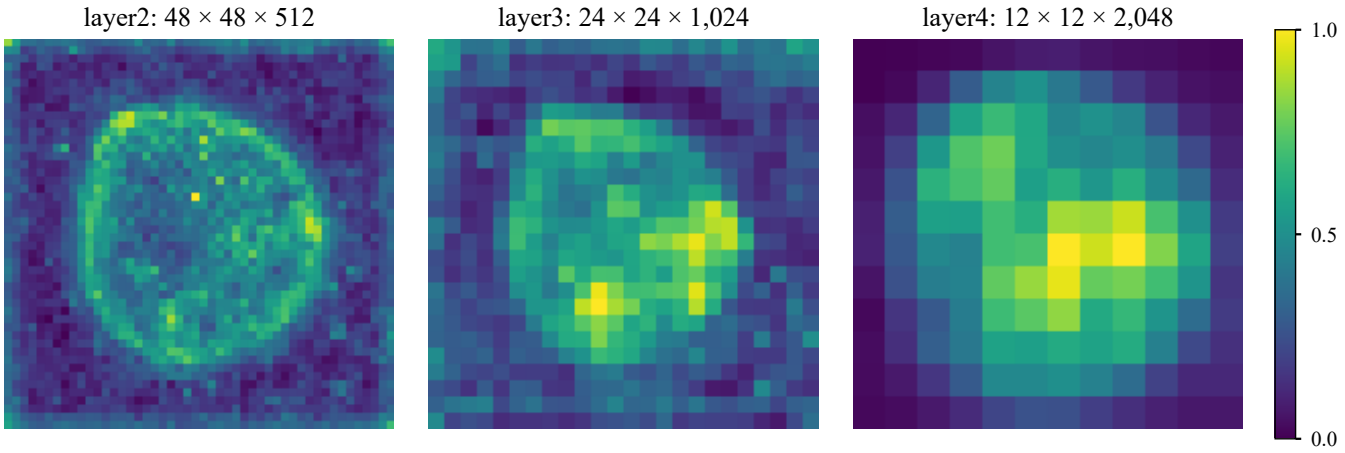


图 3: 正常榛子训练图 002 的多层特征响应。各层按通道求均值并独立作最小值—最大值归一化，颜色强度仅在同一子图内比较。

表 2: 检测分支、特征表示与融合配置

模块	设置或候选范围	两类最终配置
共享特征	Wide ResNet50-2，ImageNet-1K V1	冻结参数；输入 384×384
全局特征	三层均值池化与最大池化	7168 维；逐维标准化
局部特征	两层拼接与固定高斯投影	2304×256；投影种子 2026
SVM	$C \in \{1, 10\}$，$\gamma \in \{0.1, 1\}/7168$	$C = 10$，$\gamma = 0.1/7168$
正常记忆库	正常局部描述子随机无放回采样	8192 个描述子；8 MiB
局部聚合	$q \in \{0.005, 0.01, 0.02\}$	$q = 0.01$；最高 24 个距离取均值
分数融合	$\alpha \in \{0, 0.125, 0.25, 0.5, 1\}$	全局权重 0.875；局部权重 0.125
交叉验证	分层五折；划分种子 42	每类 250 个折外分数
融合阈值	在训练集折外分数上确定	榛子 1.507247；拉链 0.950929

1.6.5 **误报、漏检与分支互补**. 图5展示各方法的总体混淆矩阵。全局与局部分支均有 70 个 TN、2 个 FP、0 个 FN 和 30 个 TP，精确率为 $30/32 = 0.9375$，召回率为 1，F1 为 0.9677，BA 为 0.9861。融合后 TN 增加至 72，FP 降为 0；异常检出数保持 30。

两个独立分支虽然总体正确数相同，误报对象却不同。全局分支误报正常榛子 032 和正常拉链 029；局部分支误报正常拉链 023 和 036。图6给出这四张图的判定对照，两支错误对象没有重叠，融合后全部恢复为正常。

表 3: 独立检测分支与融合方法的课程固定测试集结果

产品	方法	正确数	Accuracy (%)	Precision	Recall	F1	AUROC	AP
榛子	恒判正常	40/55	72.73	0.0000	0.0000	0.0000	0.5000	0.2727
	全局 SVM	54/55	98.18	0.9375	1.0000	0.9677	1.0000	1.0000
	局部最近邻	55/55	100.00	1.0000	1.0000	1.0000	1.0000	1.0000
	融合	55/55	**100.00**	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
拉链	恒判正常	32/47	68.09	0.0000	0.0000	0.0000	0.5000	0.3191
	全局 SVM	46/47	97.87	0.9375	1.0000	0.9677	1.0000	1.0000
	局部最近邻	45/47	95.74	0.8824	1.0000	0.9375	0.9875	0.9749
	融合	47/47	**100.00**	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**

粗体标出融合方法。各方法使用自身训练内阈值，未用测试标签重新选阈值。

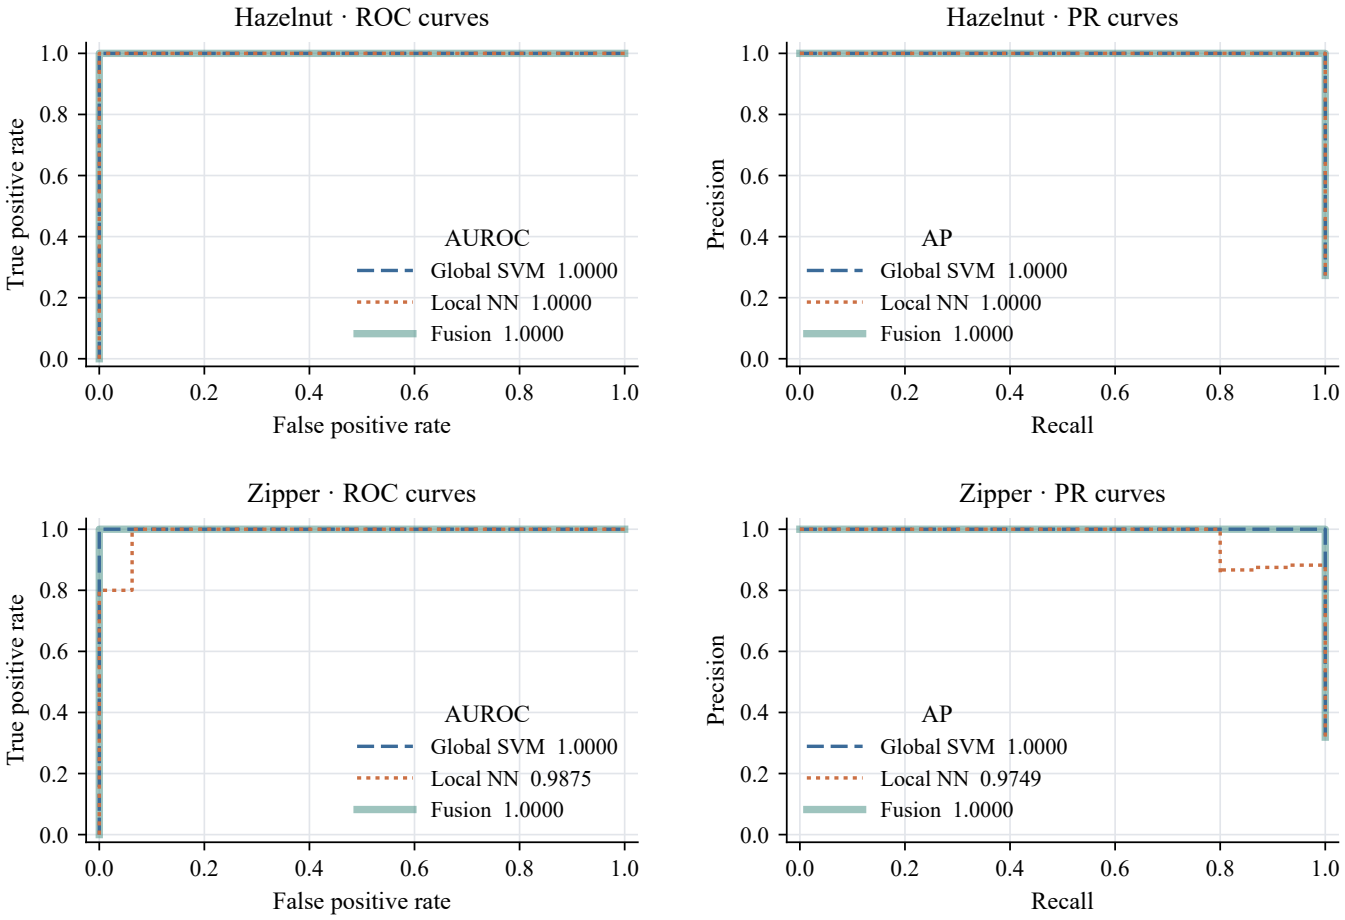


图 4: 两类产品的 ROC 和 PR 曲线。Global SVM、Local NN 和 Fusion 分别表示全局、局部和融合方法；排序相同时曲线重合。

全局分支汇总整图外观，局部分支比较单个位置与正常记忆库的差异，因此同一张图可能在两种表示下得到不同响应。该对照说明两支在本测试集上的错误具有互补性。融合使用训练内确定的尺度、权重和阈值共同决定最终标签，其收益体现在减少正常图误报。

1.6.6 **排序质量与阈值余量**. 图4展示各方法的 ROC 与 PR 曲线。榛子三个分支的曲线重合，拉链局部分支的 AUROC 为 0.9875、AP 为 0.9749，说明存在少量正常与异常样本的排序交错。两类全局分支的 AUROC 和 AP 均为 1，但固定阈值下仍各误报一张正常图。排

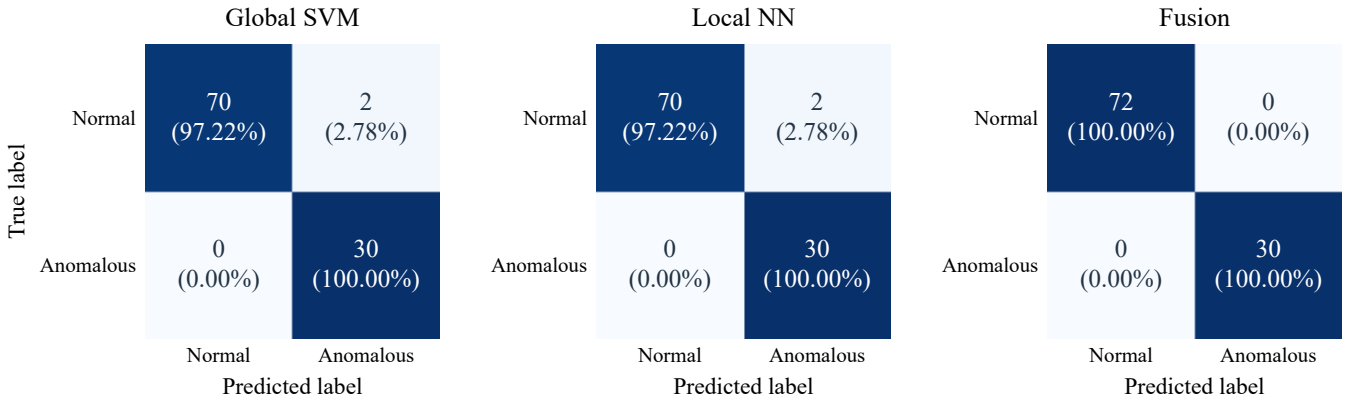


图 5: 三个检测方法的总体混淆矩阵。Normal 为正常、Anomalous 为异常；行表示真实类别，列表示预测类别，括号内为该类别的比例。

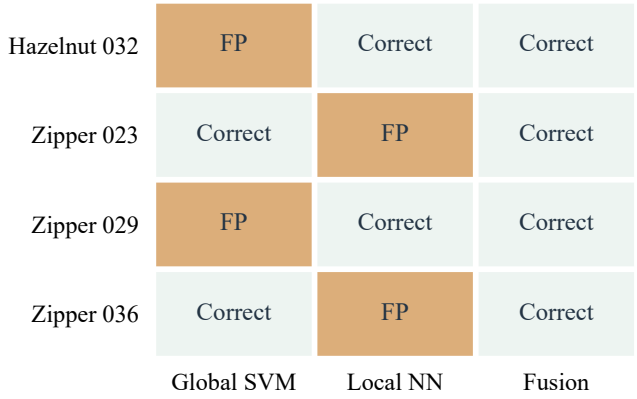


图 6: 四张正常图像在各分支下的误报情况。FP 表示误报，Correct 表示正确判为正常。

序指标衡量异常分数相对于正常分数的位置，分类结果还取决于阈值落在何处。

对每个产品，取融合分数最高的正常图与最低的异常图。表4给出四个边界样本，定义阈值余量为 $\Delta = S_c - \tau_c$。负值对应正常判定，非负值对应异常判定。

图7展示两类产品的融合分数分布。正常样本集中在各自阈值左侧，异常样本位于右侧，横轴上的短线给出逐图分数位置。拉链 029 的余量绝对值仅 0.017097，接近该产品的判定边界。其全局分数为 −0.4215，高于全局阈值 −0.4972，因此被全局分支误报；局部分数为 1.4748，低于局部阈值 1.6528。两支校准融合后，该图回到正常一侧。

榛子的最高正常分数和最低异常分数分别位于阈值两侧，余量绝对值为 0.148061 和 0.186613；拉链最低异常分数高于阈值 0.569463。余量可用于识别需要优先复查的样本，但并非校准概率，不宜直接跨产品比较。

1.6.7 **边界样本与局部热图.** 图8展示四个边界样本的原图与局部最近邻热图。使用本次冻结模型重新计算各位置相对于正常记忆库的距离，并按单张图距离场的第 99 百分位数归一化后截断至 $[0, 1]$。该显示尺度表示图内的相对响应，不同图之间的颜色强弱不能直接比较。

异常榛子 004 在左上方浅色痕迹附近具有较强响应，正常榛子 032 在果壳与底部纹理交界处也出现响应。局部距离既可能响应缺陷，也可能响应记忆库中覆盖不足的自然纹理，因此高响应区域本身不等同于异常标签。融合后，正常 032 位于阈值的正常一侧，异常 004 位于异常一侧。

正常拉链 029 的局部分数低于局部阈值，与全局分支形成分歧，融合后被判为正常。异常拉链 007 在下部齿列与部分边缘处出现响应，其融合分数 1.520392 高于阈值 0.950929，最终判为异常。课程数据提供的是图像级真值，本实验据此评价图像检测效果，热图仅用于定性回查，不报告像素级定位指标。

1.6.8 **结果核验与适用范围.** 为核对训练、预测与报告之间的一致性，使用保存的模型从 102 张原始测试图像重新提取特征，复算三个分支共 306 个分数，最大绝对差为 0。根据留存的折外分数复算 24 组参数候选、阈值和分位数校准统计量，所得选择与冻结配置一致。评价指标另由混淆计数、正负样本两两排序和同分组累计独立计算，8 组结果全部一致。

本实验的 100% 准确率对应课程给定的 102 张测试图像。该测试集在项目早期曾用于比较版本，因而当前代码在测试前冻结配置，并不意味着整个开发过程

表 4: 各产品中最接近分类间隙的正常与异常样本

产品及测试编号	真实类别	融合分数 S_c	阈值 τ_c	余量 Δ
榛子 032	正常	1.359186	1.507247	−0.148061
榛子 004	异常	1.693860	1.507247	+0.186613
拉链 029	正常	0.933833	0.950929	−0.017097
拉链 007	异常	1.520392	0.950929	+0.569463

三个数值字段由本次完整精度结果分别保留六位小数；展示值相减可能存在末位舍入差。

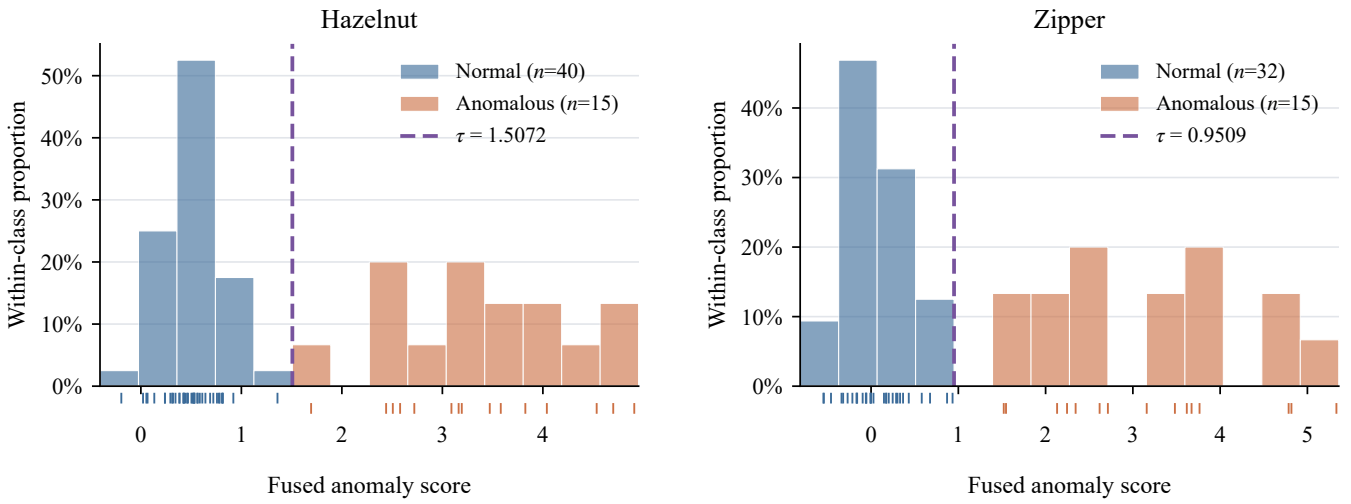


图 7: 正常与异常图像的融合分数分布。Normal 为正常、Anomalous 为异常；纵轴按真实类别归一化，短线表示单张图像，虚线为训练内阈值。

从未接触测试结果。每类测试集仅含 15 张异常，增加一次漏检就会使该类召回率下降约 6.67 个百分点。新产品批次、拍摄条件变化及未见缺陷仍需要独立测试。

训练与核验保存逐图分数、评价指标、折外参数选择记录及冻结配置。代码结构、环境配置和执行命令见随附源码说明。

1.7 小结

全局分类与局部记忆融合分别利用整图外观和正常局部参照计算异常程度。冻结的多层卷积特征为两个分支提供共享表示，训练集内的分层五折评分用于选择分支参数、校准尺度与确定融合阈值。在本次完整运行中，融合方法正确判断课程测试集全部 102 张图像，检出 30 张异常，并将两个独立分支各自的 2 次误报降至 0 次。结果表明，两种表示在这组样本上具有互补作用；其对新批次及未见缺陷的适用性仍需独立数据检验。

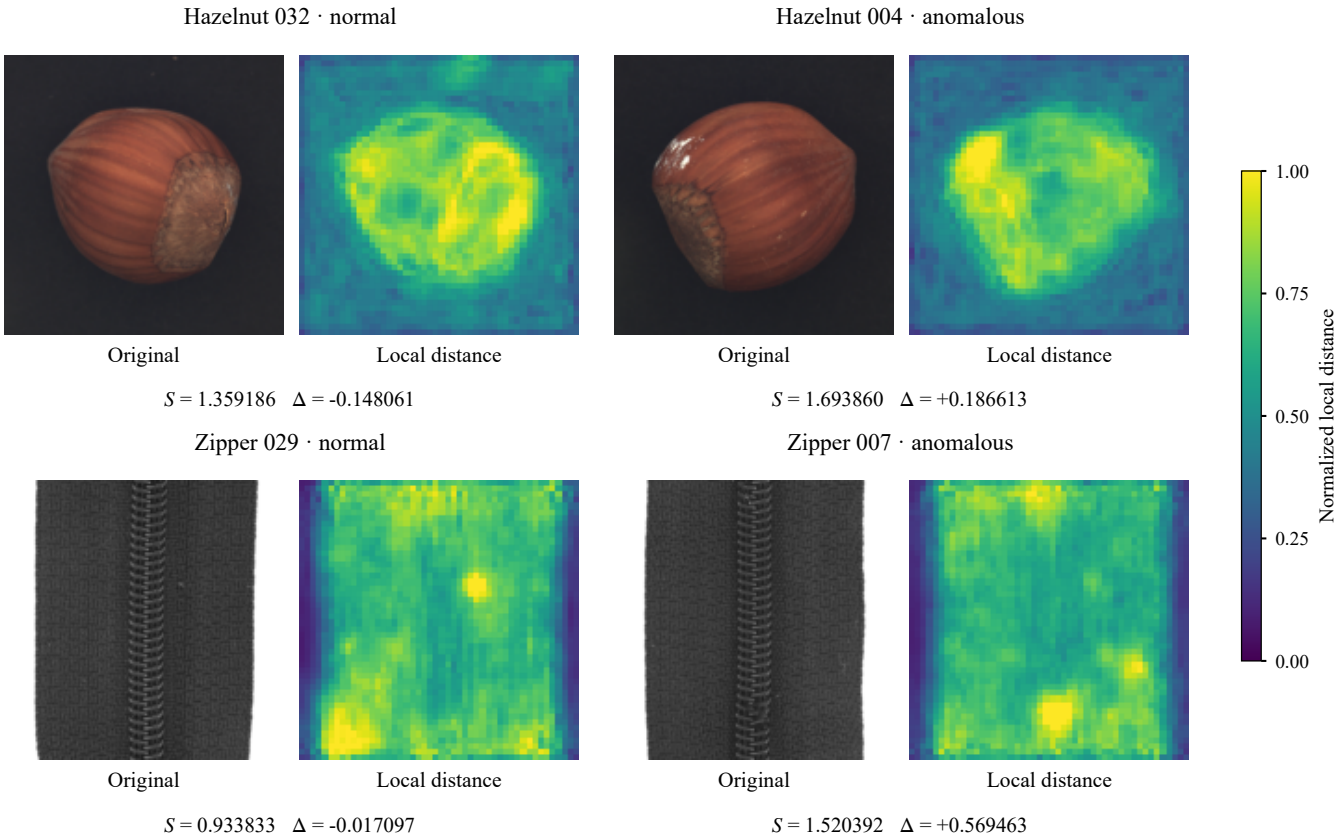


图 8: 边界样本的原图与局部异常响应。每组左侧为原图，右侧为热图；图像级标签由融合分数和固定阈值共同决定。

参考文献

[1] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. 2022. Towards Total Recall in Industrial Anomaly Detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 14318–14328. https://openaccess.thecvf.com/content/CVPR2022/html/Roth_Towards_Total_Recall_in_Industrial_Anomaly_Detection_CVPR_2022_paper.html

[2] Takaya Saito and Marc Rehmsmeier. 2015. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE* 10, 3 (2015), e0118432. doi:10.1371/journal.pone.0118432

[3] scikit-learn developers. [n. d.]. SVC: C-Support Vector Classification. Retrieved 2026-11-09 from https://scikit-learn.org/1.8/modules/generated/sklearn.svm.SVC.html

[4] Torchvision developers. [n. d.]. Wide ResNet50-2 (Torchvision 0.14). Retrieved 2026-11-09 from https://docs.pytorch.org/vision/0.14/models/generated/torchvision.models.wide_resnet50_2.html

[5] Sergey Zagoruyko and Nikos Komodakis. 2016. Wide Residual Networks. In *Proceedings of the British Machine Vision Conference*. 87.1–87.12. doi:10.5244/C.30.87