数据挖掘导论课程报告

1 GRU 多种子集成与岭回归融合方法

针对多变量观测条件下的 CO_2 浓度单步预测，我们采用 GRU 多种子集成与岭回归加权融合的方法。图 1 展示的是该方法的整体框架。标准化后的观测窗口分别输入两条分支：GRU 分支通过门控状态递推刻画非线性依赖，并对各成员预测取均值；岭回归分支将窗口按行展平后进行线性预测。两条分支的输出在标准化空间内加权融合，经反标准化得到以 ppm 为单位的 CO_2 浓度。

1.1 任务定义

设第 t 条多变量观测为 $\mathbf{x}_t \in \mathbb{R}^F$，其中 F 为特征维度。预测目标为 CO_2 浓度 $y_t = x_{t,j_*}$，j_* 表示目标特征的索引。令输入窗口长度为 L，模型根据此前 L 条观测预测目标浓度：

$$\mathbf{X}_t = [\mathbf{x}_{t-L}, \ldots, \mathbf{x}_{t-1}]^\top \in \mathbb{R}^{L\times F}, \qquad \widehat{y}_t = f(\mathbf{X}_t). \tag{1}$$

1.2 共享特征与目标标准化

气象变量的量纲与数值尺度存在差异，因此两条分支统一使用标准化后的窗口。记第 j 个特征的均值与标准差为 μ_j 和 s_j，输入与目标的变换为

$$\widetilde{X}_{i,\tau,j} = \frac{X_{i,\tau,j} - \mu_j}{s_j}, \qquad \widetilde{y}_i = \frac{y_i - \mu_y}{s_y}, \tag{2}$$

其中 $\mu_y = \mu_{j_*}$、$s_y = s_{j_*}$，即标签与输入中的 CO_2 特征使用相同的缩放尺度。两条分支的目标尺度保持一致，为后续融合预测值提供统一的数值基础。统计量的估计方式见第 1.7.1 节。

1.3 门控循环预测器

非线性分支采用门控循环单元（GRU）[1]，根据当前观测调节历史隐藏状态对预测表示的影响。每个预测器包含两层单向 GRU，隐藏维度均为 H。对其中一层，记窗口位置 τ 的输入为 $\mathbf{u}_\tau$，前一位置的隐藏状态为 $\mathbf{h}_{\tau-1} \in \mathbb{R}^H$。重置门与更新门分别为

$$\mathbf{r}_\tau = \sigma\big(\mathbf{W}_{ir}\mathbf{u}_\tau + \mathbf{b}_{ir} + \mathbf{W}_{hr}\mathbf{h}_{\tau-1} + \mathbf{b}_{hr}\big), \tag{3}$$

$$\mathbf{z}_\tau = \sigma\big(\mathbf{W}_{iz}\mathbf{u}_\tau + \mathbf{b}_{iz} + \mathbf{W}_{hz}\mathbf{h}_{\tau-1} + \mathbf{b}_{hz}\big). \tag{4}$$

候选状态和隐藏状态更新为[4]：

$$\mathbf{n}_\tau = \tanh\Big(\mathbf{W}_{in}\mathbf{u}_\tau + \mathbf{b}_{in} + \mathbf{r}_\tau \odot \big(\mathbf{W}_{hn}\mathbf{h}_{\tau-1} + \mathbf{b}_{hn}\big)\Big), \tag{5}$$

$$\mathbf{h}_\tau = (\mathbf{1} - \mathbf{z}_\tau) \odot \mathbf{n}_\tau + \mathbf{z}_\tau \odot \mathbf{h}_{\tau-1}. \tag{6}$$

其中，σ 为 Sigmoid 函数，$\odot$ 表示逐元素乘法。重置门控制历史状态在候选状态中的参与程度，更新门控制旧状态的保留比例。式 (5) 先对历史状态进行仿射变换，再施加重置门。

第一层接收标准化特征向量，第二层接收经过 Dropout[5] 的第一层输出：

$$\mathbf{u}_{i,\tau}^{(1)} = \widetilde{\mathbf{x}}_{i,\tau}, \qquad \mathbf{u}_{i,\tau}^{(2)} = \mathcal{D}_p(\mathbf{h}_{i,\tau}^{(1)}), \tag{7}$$

这里 $\widetilde{\mathbf{x}}_{i,\tau}$ 为第 i 个标准化窗口在位置 τ 的特征向量，$\mathcal{D}_p$ 表示丢弃概率为 p 的 Dropout 算子，作用于两层之间的输出。

第二层最后一个位置的隐藏状态用于生成浓度预测。对第 k 个集成成员，回归头依次执行全连接变换、ReLU、Dropout 和线性输出：

$$\mathbf{a}_i^{(k)} = \mathrm{ReLU}(\mathbf{W}_1^{(k)}\mathbf{h}_{i,L}^{(2,k)} + \mathbf{b}_1^{(k)}), \tag{8}$$

$$f_{\theta_k}(\widetilde{\mathbf{X}}_i) = \mathbf{W}_2^{(k)}\mathcal{D}_p(\mathbf{a}_i^{(k)}) + b_2^{(k)}, \tag{9}$$

其中 $\mathbf{W}_1^{(k)} \in \mathbb{R}^{d\times H}$，$\mathbf{W}_2^{(k)} \in \mathbb{R}^{1\times d}$，$d$ 为回归头的隐藏维度，θ_k 表示第 k 个预测器的参数。输出为标准化后的标量浓度，不施加概率范围约束。

1.4 循环预测器的损失与集成

记训练样本索引集为 $\mathcal{I}_{\mathrm{tr}}$，样本数为 $M_{\mathrm{tr}} = |\mathcal{I}_{\mathrm{tr}}|$。各 GRU 成员分别使用标准化标签上的均方误差（MSE）作为目标：

$$\mathcal{L}_{\mathrm{G}}(\theta_k) = \frac{1}{M_{\mathrm{tr}}}\sum_{i\in\mathcal{I}_{\mathrm{tr}}}\big(f_{\theta_k}(\widetilde{\mathbf{X}}_i) - \widetilde{y}_i\big)^2. \tag{10}$$

集成包含 K 个预测器，对各成员的标准化预测取算术平均：

$$g_i = \frac{1}{K}\sum_{k=1}^{K} f_{\theta_k}(\widetilde{\mathbf{X}}_i). \tag{11}$$

该操作在预测空间整合多个非线性映射。

1.5 正则化线性预测分支

线性分支为窗口内不同时间位置的观测变量分别设置回归系数，通过加权求和预测目标浓度。将标准

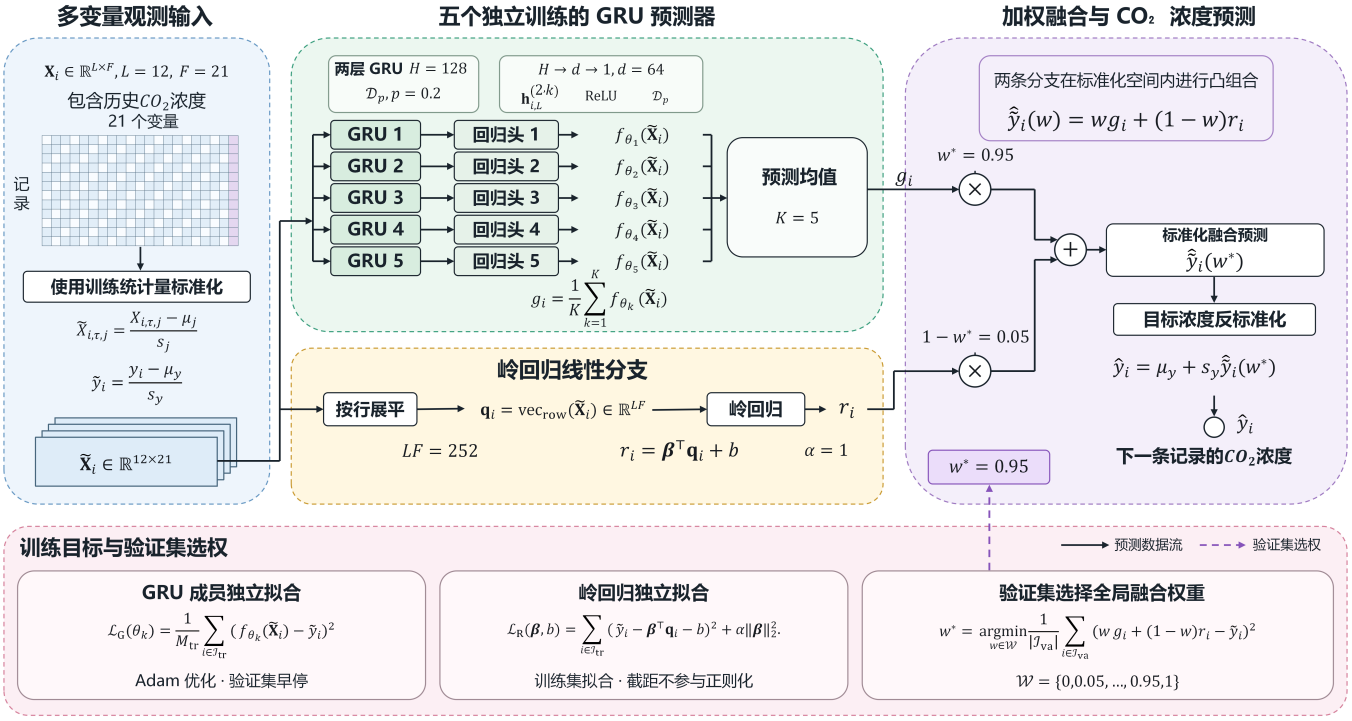


图 1: GRU 多种子集成与岭回归融合的 CO_2 浓度预测框架

化窗口按行展平为 LF 维向量后，采用岭回归[2] 计算预测：

$$\mathbf{q}_i = \mathrm{vec}_{\mathrm{row}}(\widetilde{\mathbf{X}}_i) \in \mathbb{R}^{LF}, \qquad r_i = \boldsymbol{\beta}^{\top}\mathbf{q}_i + b. \tag{12}$$

岭回归与 GRU 使用相同的输入观测和标准化标签，其系数与截距通过下式拟合：

$$\mathcal{L}_{\mathrm{R}}(\boldsymbol{\beta}, b) = \sum_{i\in\mathcal{I}_{\mathrm{tr}}} (\widetilde{y}_i - \boldsymbol{\beta}^{\top}\mathbf{q}_i - b)^2 + \alpha\|\boldsymbol{\beta}\|_2^2. \tag{13}$$

正则项约束系数幅度，以处理滞后输入之间的相关性，截距 b 不参与惩罚。

1.6 加权融合与浓度还原

两条分支的预测通过凸组合得到标准化融合预测：

$$\widehat{\widetilde{y}}_i(w) = w g_i + (1-w) r_i, \qquad w \in [0,1], \tag{14}$$

其中 w 控制 GRU 集成的贡献，$1-w$ 为岭回归的权重。所有样本共享同一个组合系数，两个端点分别对应单独使用岭回归或 GRU 集成。记最终采用的组合系数为 w^*，其选择过程见第 1.7.2 节。利用目标统计量将融合结果还原为浓度：

$$\widehat{y}_i = \mu_y + s_y \left[w^* \frac{1}{K}\sum_{k=1}^{K} f_{\theta_k}(\widetilde{\mathbf{X}}_i) + (1-w^*) r_i \right]. \tag{15}$$

1.7 实验

1.7.1 数据预处理与划分. 实验读取 GBK 编码的气象数据，共有 26,200 条记录、21 个数值变量以及一列日期。预测目标为 CO_2 浓度，单位为 ppm。当前程序先按 `date` 字符串排序，再将所有不大于 −9998 的数值设为缺失，包括传感器占位值 −9999。原始数据共有 45 处此类异常值，其中目标列占 34 处。

缺失值在完整数据表上按当前行位置进行双向线性插值。对于有效观测位置 $a < t < b$，第 j 个变量的填充值为

$$x_{t,j} = x_{a,j} + \frac{t-a}{b-a}(x_{b,j} - x_{a,j}). \tag{16}$$

序列边缘的缺失值按双向补全规则处理，插值后数值列无缺失值。

清洗后以长度 $L = 12$、步长为 1 的滑动窗口构造单步预测样本，得到 26,188 个 12×21 输入窗口。按处理后的样本索引连续划分训练、验证与测试集，样本数分别为 17,809、3,142 和 5,237。测试集取全部样本的最后 20%，验证集取剩余样本的最后 15%。图 2 展示的是训练集、验证集和测试集的 CO_2 浓度标签分布。

输入标准化器仅在训练窗口上拟合。第 j 个特征的均值与总体方差由全部训练窗口中的观测位置计

算：

$$\mu_j = \frac{1}{M_{\mathrm{tr}} L} \sum_{i \in \mathcal{I}_{\mathrm{tr}}} \sum_{\tau=1}^{L} X_{i,\tau,j}, \tag{17}$$

$$s_j^2 = \frac{1}{M_{\mathrm{tr}} L} \sum_{i \in \mathcal{I}_{\mathrm{tr}}} \sum_{\tau=1}^{L} (X_{i,\tau,j} - \mu_j)^2. \tag{18}$$

训练、验证和测试集共用这组统计量，按式 (2) 变换；目标值使用训练输入中 CO_2 特征对应的均值和标准差缩放。

1.7.2 **实验配置与训练细节**. GRU 分支使用两层单向循环网络，隐藏维度为 $H = 128$，回归头的隐藏维度为 $d = 64$，采用 $128 \to 64 \to 1$ 的全连接结构。单个预测器的参数集合 θ_k 包含两层 GRU 和回归头，共有 165,377 个可训练参数。集成成员数为 $K = 5$，五个预测器合计包含 826,885 个神经网络参数。层间及回归头的 Dropout 比例均为 $p = 0.2$。训练时，$\mathcal{D}_p$ 随机将部分分量置零，并将保留分量乘以 $1/(1-p)$；验证与测试时关闭 Dropout，该算子为恒等映射。

五个成员分别以种子 0 至 4 训练，批次大小为 256，最多训练 200 轮，以式 (10) 为损失函数。优化器为 Adam[3]，初始学习率为 5×10^{-4}，动量参数为 $\beta_1 = 0.9$、$\beta_2 = 0.999$，$\epsilon = 10^{-8}$，权重衰减为零。每轮打乱训练窗口的送入顺序而保持窗口内部排列不变，反向传播后将全局梯度范数裁剪至不超过 1。训练损失在标准化标签上计算；对同一组预测，还原为 ppm 后的 MSE 等于 $s_y^2 \mathcal{L}_{\mathrm{G}}$，因此两种量纲下的 MSE 排序相同。

每轮结束后在完整验证集上计算 MSE。学习率调度器的容忍计数为 8、衰减因子为 0.5、最低学习率为 10^{-6}。验证损失连续 25 轮未超过 10^{-6} 的改善阈值时触发早停，训练结束后恢复验证损失最优的参数。训练种子在模型构建后设置，作用于后续训练过程。

岭回归独立于 GRU 拟合，包含 LF 个系数和一个截距，式 (13) 的正则化参数取 $\alpha = 1$。

GRU 集成按式 (11) 对五个成员的预测取均值，作为集成分支的输出。两条分支完成训练后，固定各自的参数，在候选集合 $\mathcal{W} = \{0, 0.05, \ldots, 0.95, 1\}$ 中搜索融合权重。记验证样本索引集为 $\mathcal{I}_{\mathrm{va}}$，通过最小化验证集 MSE 选择全局组合系数：

$$w^* = \arg\min_{w \in \mathcal{W}} \frac{1}{|\mathcal{I}_{\mathrm{va}}|} \sum_{i \in \mathcal{I}_{\mathrm{va}}} \left(w g_i + (1-w) r_i - \widetilde{y}_i \right)^2. \tag{19}$$

候选集合包含 21 个权重，保存的最优 GRU 权重为 0.95。GRU 参数、岭回归系数和融合权重由三个独立阶段确定，融合系数不参与神经网络的梯度更新，测试标签不参与权重搜索。测试阶段固定已选择的模型参数、标准化统计量与融合权重，不使用验证集重新拟合分支。对照项包括持久化预测、独立 Ridge 和五个 GRU 的预测均值；这些比较项用于解释当前融合模型的效果。

1.7.3 **评价指标**. 所有指标均在反标准化后的测试集预测上计算。记测试样本数为 $n = 5{,}237$，真实值为 y_i，预测值为 $\widehat{y}_i$，测试集真实值均值为 $\bar{y} = n^{-1} \sum_{i=1}^{n} y_i$。采用均方根误差（RMSE）、平均绝对误差（MAE）、决定系数（R^2）和平均绝对百分比误差（MAPE）：

$$\mathrm{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (y_i - \widehat{y}_i)^2}, \tag{20}$$

$$\mathrm{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \widehat{y}_i|, \tag{21}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \widehat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}, \tag{22}$$

$$\mathrm{MAPE}(\%) = \frac{100}{n} \sum_{i=1}^{n} \left| \frac{y_i - \widehat{y}_i}{y_i} \right|. \tag{23}$$

RMSE 和 MAE 的单位为 ppm，数值越低越好；R^2 越高越好。

1.7.4 **实验结果与分析**. 表 1 展示了 GRU–Ridge 融合模型与各对照方法在测试集上的预测性能。融合模型在 RMSE 和 R^2 上取得最优值，分别为 5.4047 ppm 和 0.9460。相较独立 GRU 集成，融合后的 RMSE 从 5.4372 ppm 降至 5.4047 ppm，下降约 0.60%；MAE 从 2.8057 ppm 降至 2.7684 ppm，下降约 1.33%。

图 3 展示的是持久化预测、Ridge、GRU 集成和融合模型在 RMSE、MAE、R^2 与 MAPE 四项指标上的测试结果。以持久化预测为参照，融合模型的 RMSE 与 MAE 相对变化分别为 -12.92% 和 $+5.28\%$。

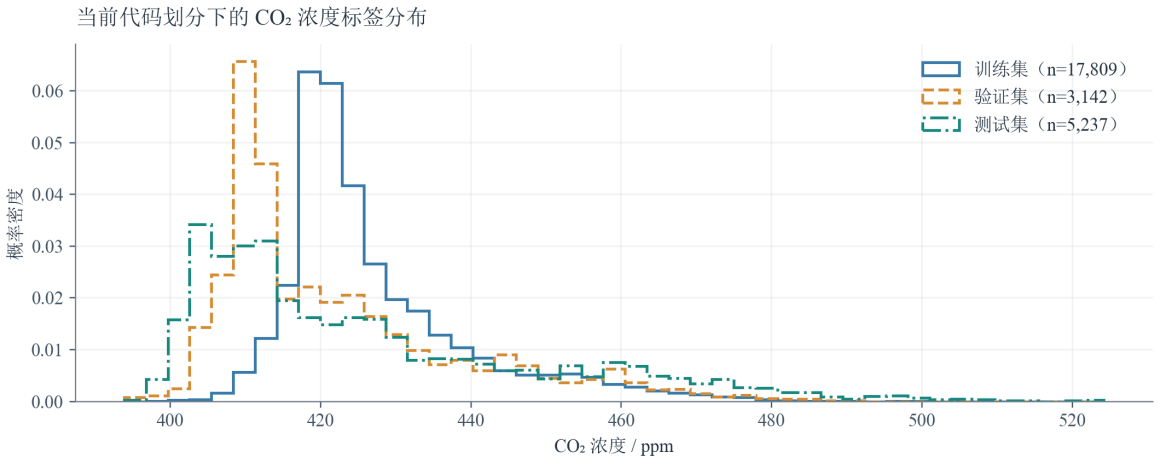


图 2: 当前代码划分下的 CO_2 浓度标签分布

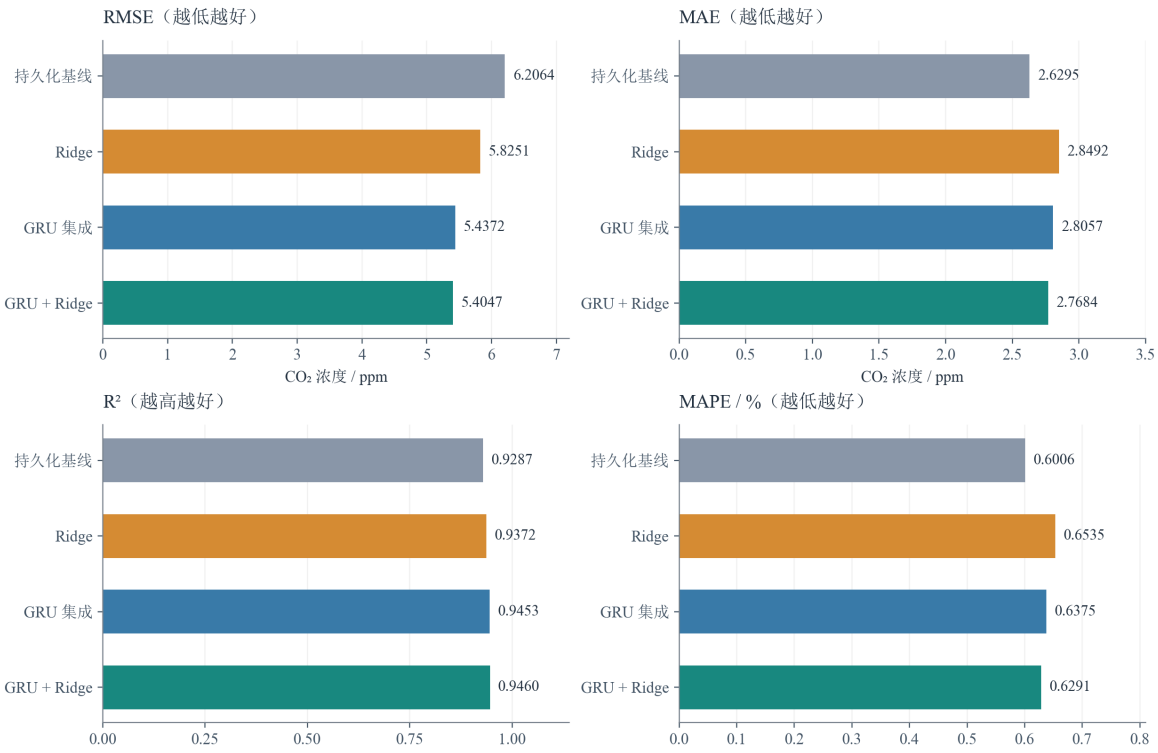


图 3: 当前模型与三个比较项的测试指标

表 1: 当前实现的测试集结果。粗体表示每列最优值。

方法	RMSE ↓	MAE ↓	R^2 ↑	MAPE (%) ↓
持久化预测	6.2064	**2.6295**	0.9287	**0.6006**
Ridge	5.8251	2.8492	0.9372	0.6535
GRU 集成	5.4372	2.8057	0.9453	0.6375
GRU + Ridge（当前模型）	**5.4047**	2.7684	**0.9460**	0.6291

图 4 展示的是测试集 CO_2 浓度预测值与真实值的散点分布，散点总体沿 $\hat{y} = y$ 分布。

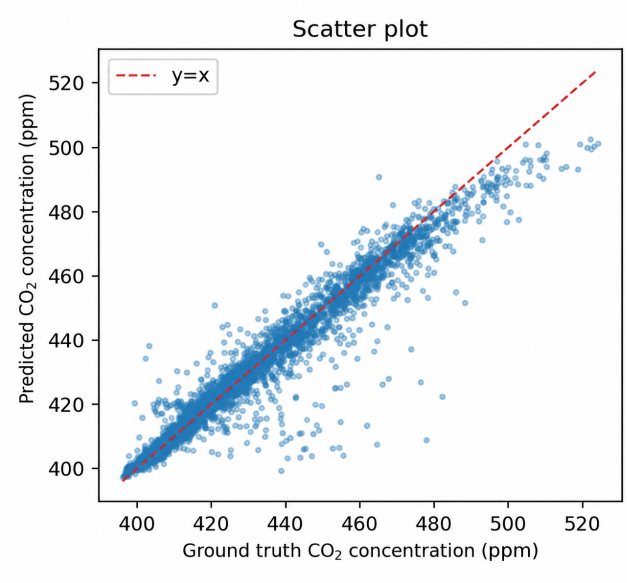


图 4: 测试集 CO_2 浓度预测值与真实值的散点图

参考文献

[1] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. 2014. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 1724–1734. doi:10.3115/v1/D14-1179

[2] Arthur E. Hoerl and Robert W. Kennard. 1970. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics* 12, 1 (1970), 55–67. doi:10.1080/00401706.1970.10488634

[3] Diederik P. Kingma and Jimmy Ba. 2015. Adam: A Method for Stochastic Optimization. In *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/1412.6980

[4] PyTorch Contributors. n.d.. GRU: PyTorch 2.11 Documentation. https://docs.pytorch.org/docs/2.11/generated/torch.nn.GRU.html. Accessed November 5, 2026.

[5] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. 2014. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *Journal of Machine Learning Research* 15, 56 (2014), 1929–1958. https://jmlr.org/papers/v15/srivastava14a.html