数据挖掘导论课程报告

1 多检测器秩融合的无监督甲状腺疾病判断方法

甲状腺疾病判断以正常样本的分布为参照，识别脱敏指标中的异常偏离。单个指标的低密度取值与多个指标的组合偏离分别提供异常线索，因此采用 Isolation Forest、直方图异常评分（Histogram-based Outlier Score，HBOS）和最小协方差行列式（Minimum Covariance Determinant，MCD）构成并行检测分支。三个分支共享特征表示，从隔离路径、边缘密度和稳健距离三个角度计算异常程度，再通过秩归一化与等权平均形成统一评分。

图 1 展示的是多检测器秩融合的疾病判断框架。上方流程使用正常样本估计标准化统计量并拟合检测器；下方流程将待测样本转换为共享特征表示，再分别计算隔离路径、边缘密度和稳健距离对应的异常分数。各分支在同一待测批次内进行平均秩归一化，通过等权平均得到最终异常分数，并根据阈值判断样本是否患病。

1.1 任务定义

设正常样本集合为

$$\mathcal{D}_{\mathrm{tr}} = \{\boldsymbol{x}_i\}_{i=1}^{N}, \qquad \boldsymbol{x}_i \in \mathbb{R}^D, \tag{1}$$

其中 D 为原始特征维度。待测批次记为 $\mathcal{B} = \{\boldsymbol{x}'_i\}_{i=1}^{M}$，对应的评价标签为 $y_i \in \{0,1\}$，其中 0 表示正常，1 表示患病。模型学习正常样本的统计特征，为每个待测样本给出异常分数 S_i。较大的分数表示该样本更偏离正常模式。给定阈值 τ，二元判断为

$$\widehat{y}_i(\tau) = \mathbb{I}(S_i \geq \tau), \tag{2}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数。

1.2 共享特征与标准化

设选定的特征索引集合为 $\mathcal{J}$，通过投影 $P_{\mathcal{J}}$ 得到 $d = |\mathcal{J}|$ 维输入向量 $\boldsymbol{u} = P_{\mathcal{J}}\boldsymbol{x}$。

对正常样本中第 j 个选定特征计算均值与标准差

$$\begin{aligned} \mu_j &= \frac{1}{N}\sum_{i=1}^{N} u_{i,j}, \\ \sigma_j &= \sqrt{\frac{1}{N}\sum_{i=1}^{N}(u_{i,j}-\mu_j)^2}. \end{aligned} \tag{3}$$

样本的标准化表示为

$$z_j = \frac{u_j - \mu_j}{\sigma_j}, \qquad \boldsymbol{z} \in \mathbb{R}^d. \tag{4}$$

该变换将各维度表示为相对于正常样本均值的标准差偏移。正常样本与待测样本使用相同的统计量，分别记其标准化表示为 $\boldsymbol{z}_i$ 与 $\boldsymbol{z}'_i$。

1.3 Isolation Forest 随机隔离分支

Isolation Forest 通过随机特征和随机切分点递归划分样本，利用隔离路径长度衡量异常程度 [2]。在一棵隔离树的节点内，选取一个特征，并在该特征的取值范围内随机产生切分点，将样本送入左右子节点。偏离密集区域的样本通常能够通过较少的切分被隔离，从而获得较短的路径。

设森林包含 T 棵树，每棵树使用 ψ 个正常样本。样本 $\boldsymbol{z}$ 在第 t 棵树中到达叶节点的深度为 $e_t(\boldsymbol{z})$，叶节点包含的样本数为 $n_t(\boldsymbol{z})$。考虑叶节点内尚未完全隔离的样本后，路径长度为

$$h_t(\boldsymbol{z}) = e_t(\boldsymbol{z}) + c\big(n_t(\boldsymbol{z})\big), \tag{5}$$

其中归一化函数采用

$$c(n) = \begin{cases} 0, & n \leq 1, \\ 1, & n = 2, \\ 2\big(\ln(n-1)+\gamma\big) - \dfrac{2(n-1)}{n}, & n > 2, \end{cases} \tag{6}$$

γ 为欧拉常数。根据多棵树的平均路径得到异常分数

$$s_{\mathrm{I}}(\boldsymbol{z}) = 2^{-\frac{1}{Tc(\psi)}\sum_{t=1}^{T} h_t(\boldsymbol{z})}. \tag{7}$$

平均路径越短，s_{I} 越大，表示样本越容易被随机切分隔离。

1.4 HBOS 边缘密度分支

HBOS 对每个特征建立一维直方图，并汇总样本在各维度上的低密度程度 [1]。对第 j 维划分 B 个等宽区间，记第 b 个区间为 $I_{j,b}$，宽度为 $\Delta_{j,b}$。落入该区间的正常样本数为

$$n_{j,b} = \sum_{i=1}^{N} \mathbb{I}(z_{i,j} \in I_{j,b}). \tag{8}$$

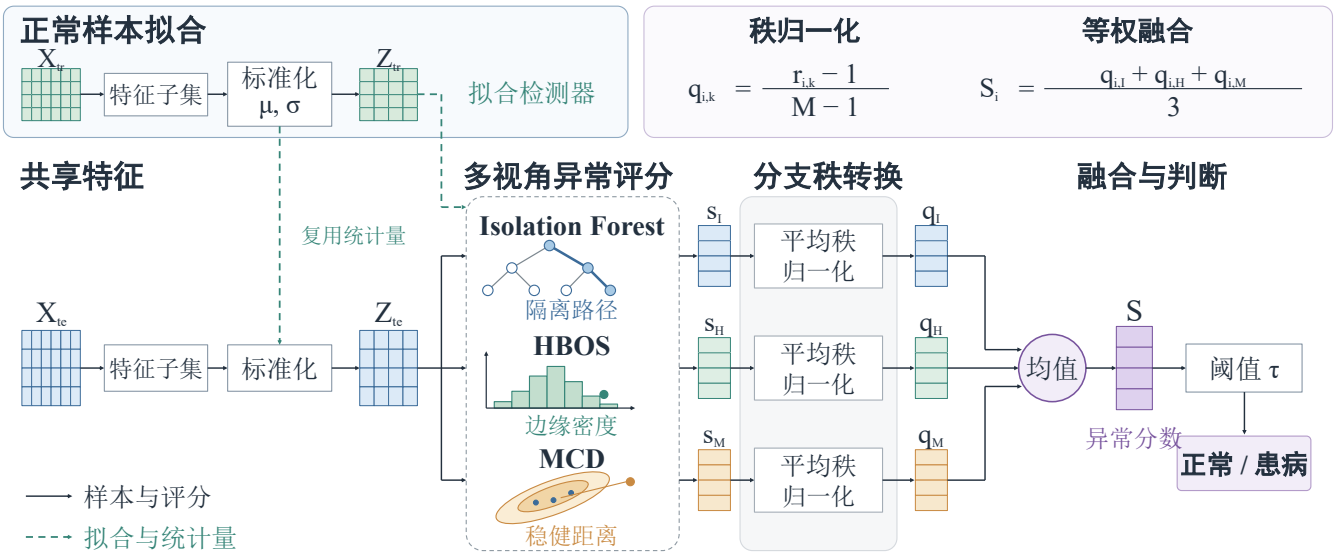


图 1: 多检测器秩融合的甲状腺疾病判断框架

这些频数对应离散区间概率的极大似然估计。设区间概率向量为 $\boldsymbol{p}_j$，其估计目标及闭式解为

$$\begin{aligned}\widehat{\boldsymbol{p}}_j &= \arg\min_{\substack{p_{j,b}\ge 0\\ \sum_b p_{j,b}=1}} \left(-\sum_{b=1}^{B} n_{j,b}\log p_{j,b}\right),\\ \widehat{p}_{j,b} &= \frac{n_{j,b}}{N}.\end{aligned} \tag{9}$$

据此得到区间内的概率密度估计

$$\widehat{f}_j(v) = \frac{n_{j,b}}{N\Delta_{j,b}}, \qquad v \in I_{j,b}. \tag{10}$$

以 α 平滑密度后，分支异常分数定义为

$$s_{\mathrm{H}}(\boldsymbol{z}) = -\sum_{j=1}^{d} \log_2\big(\widehat{f}_j(z_j) + \alpha\big). \tag{11}$$

低密度区间对异常分数的贡献更大，使单个指标上的偏离能够进入综合评分。直方图范围外的密度按边界规则延拓，具体设置见实验部分。

1.5 MCD 稳健距离分支

MCD 通过协方差行列式最小化估计正常样本的中心与散布结构 [3]。设正常样本索引的候选子集为 $\mathcal{H}$，且 $|\mathcal{H}| = h$，对应均值与协方差为

$$\begin{aligned}\boldsymbol{\mu}_{\mathcal{H}} &= \frac{1}{h}\sum_{i\in\mathcal{H}} \boldsymbol{z}_i,\\ \Sigma_{\mathcal{H}} &= \frac{1}{h}\sum_{i\in\mathcal{H}} (\boldsymbol{z}_i - \boldsymbol{\mu}_{\mathcal{H}})(\boldsymbol{z}_i - \boldsymbol{\mu}_{\mathcal{H}})^{\mathsf{T}}.\end{aligned} \tag{12}$$

估计目标为

$$\mathcal{H}^* = \arg\min_{\substack{\mathcal{H}\subseteq\{1,\dots,N\}\\ |\mathcal{H}|=h}} \det(\Sigma_{\mathcal{H}}). \tag{13}$$

协方差行列式衡量所选样本的整体散布规模。FAST-MCD 通过候选子集搜索求解这一估计问题，经校正与重加权得到稳健中心 $\widehat{\boldsymbol{\mu}}_{\mathrm{R}}$ 和协方差 $\widehat{\Sigma}_{\mathrm{R}}$。

对待测向量，使用平方马氏距离作为异常分数

$$s_{\mathrm{M}}(\boldsymbol{z}) = (\boldsymbol{z} - \widehat{\boldsymbol{\mu}}_{\mathrm{R}})^{\mathsf{T}} \widehat{\Sigma}_{\mathrm{R}}^{\dagger} (\boldsymbol{z} - \widehat{\boldsymbol{\mu}}_{\mathrm{R}}), \tag{14}$$

其中 $\dagger$ 表示矩阵伪逆。协方差将特征之间的相关关系纳入距离计算，刻画样本相对于正常中心的联合偏离。

1.6 平均秩归一化与等权融合

三个分支的分数尺度不同，融合时使用样本在各分支中的相对异常次序。记检测器索引集合为 $\mathcal{K} = \{\mathrm{I}, \mathrm{H}, \mathrm{M}\}$，分支数为 $K = |\mathcal{K}|$。对同一待测批次，分支评分 $s_{i,k} = s_k(\boldsymbol{z}'_i)$ 的升序平均秩为

$$r_{i,k} = \mathrm{rank}_{\mathrm{avg}}\big(s_{i,k}\,;\, s_{1,k}, \dots, s_{M,k}\big). \tag{15}$$

分数相同的样本使用其占据名次的平均值，秩的起点为 1。将平均秩转换为

$$q_{i,k} = \frac{r_{i,k} - 1}{M - 1}, \qquad q_{i,k} \in [0, 1]. \tag{16}$$

该映射保留各分支的排序信息，并将其置于统一的数值范围内。对 K 个检测器等权平均，得到

$$S_i = \frac{1}{K}\sum_{k\in\mathcal{K}} q_{i,k}. \tag{17}$$

样本在多个分支中获得较高异常名次时，融合分数相应增大。S_i 表示样本在该待测批次内的相对异常程度，代入式 (2) 得到二元判断。

1.7 实验

1.7.1 数据预处理与划分. 实验使用课程任务提供的 Thyroid 脱敏数据，共 3,772 条记录，每条记录包含六个连续特征。训练集包含 1,839 个正常样本，测试集包含 1,839 个正常样本和 94 个患病样本，患病比例为 4.86%。表 1 展示了数据划分及类别构成。

表 1: Thyroid 数据划分与类别构成

集合	正常	患病	合计
训练集	1,839	0	1,839
测试集	1,839	94	1,933
合计	3,678	94	3,772

数据特征均为有限数值。选取第 2、3、4 和 6 个特征组成四维输入，使用训练集的均值与标准差完成标准化。实验沿用任务给定的划分和原始记录，测试集中有 56 条正常记录的完整六维特征与训练记录相同。

图 2 展示的是正常与患病样本在六个特征上的经验累积分布。患病样本的第 2 个特征向较大取值偏移，第 3、4 和 6 个特征则集中于较低取值区间。选定的四个特征据此描述两类样本的分布差异。

1.7.2 实验配置与拟合流程. 三个检测器均使用 PyOD 实现 [5]，在正常训练样本上分别拟合。表 2 展示了检测器与融合配置。Isolation Forest 每棵树抽取两个特征，深度上限为 $\lceil \log_2 256 \rceil = 8$。MCD 的原始支持子集大小为 $\lceil (N + d + 1)/2 \rceil = 922$，拟合时执行校正与重加权，随机状态采用库默认设置。

HBOS 对范围外的取值采用边界延拓。若取值与边界的距离不超过边缘区间宽度的 η 倍，则使用边缘区间密度，否则采用该维度的最小区间密度。三个检测器的 `contamination` 参数用于内部阈值计算。Isolation Forest 输出评分在式 (7) 的基础上增加常数偏移，所得平均秩相同。

特征子集和检测器组合依据测试集上的分布分析与评价结果确定。测试标签用于方案选择、指标计算和阈值选择，最终阈值取测试集 F1 最大的候选值

$$\tau^{*} = \arg\max_{\tau \in \mathcal{T}_{\mathrm{te}}} F_1(\tau), \tag{18}$$

其中 $\mathcal{T}_{\mathrm{te}}$ 为测试分数中的不同取值。各独立分支同样采用自身评分上的最佳 F1 阈值。

表 2: 检测器与融合配置

模块	参数	取值
Isolation Forest	树数 / 子样本数	1,000 / 256
Isolation Forest	特征比例 / 种子	0.5 / 42
HBOS	区间数	10
HBOS	α / η	0.1 / 0.5
MCD	原始支持样本数	922
全部分支	`contamination`	0.05
秩融合	分支数 / 权重	3 / 1/3

1.7.3 评价指标. 评价将患病样本作为正类。为同时描述完整排序和二元判断，报告 AUROC、AUPRC、F1、精确率与召回率。

AUROC 衡量随机抽取的患病样本排在正常样本之前的比例。设正类和负类索引集合分别为 $\mathcal{P}$ 与 $\mathcal{N}$，样本数为 n_+ 与 n_-，则

$$\mathrm{AUROC} = \frac{1}{n_+ n_-} \sum_{i \in \mathcal{P}} \sum_{j \in \mathcal{N}} \Big[\mathbb{I}(S_i > S_j) + \tfrac{1}{2} \mathbb{I}(S_i = S_j) \Big]. \tag{19}$$

ROC 曲线以假阳性率为横轴、真阳性率为纵轴，展示阈值变化时的类别区分情况。

AUPRC 使用平均精确率（Average Precision，AP）计算 [4]。按阈值降低、召回率递增的顺序，记第 ℓ 个工作点的精确率和召回率为 P_ℓ 与 R_ℓ，则

$$\mathrm{AUPRC} = \mathrm{AP} = \sum_{\ell} (R_\ell - R_{\ell-1}) P_\ell, \tag{20}$$

其中初始召回率取 $R_0 = 0$。该指标根据召回率增量对精确率加权，反映患病样本在高分排序中的集中程度。

在给定阈值下，记真正例、假正例和假负例数分别为 TP、FP 和 FN。精确率、召回率和 F1 定义为

$$\begin{aligned} \mathrm{Precision} &= \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}, \\ \mathrm{Recall} &= \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}, \\ F_1 &= \frac{2\,\mathrm{Precision}\,\mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}. \end{aligned} \tag{21}$$

精确率描述判为患病的样本中实际患病者的比例，召回率描述全部患病样本中被识别的比例，F1 汇总这两个方面。

1.7.4 实验结果与分析. 表 3 展示了三个独立检测分支与秩融合方法的测试集结果。融合方法的 AUROC 为 0.9846，AUPRC 为 0.9060。相较 Isolation Forest，

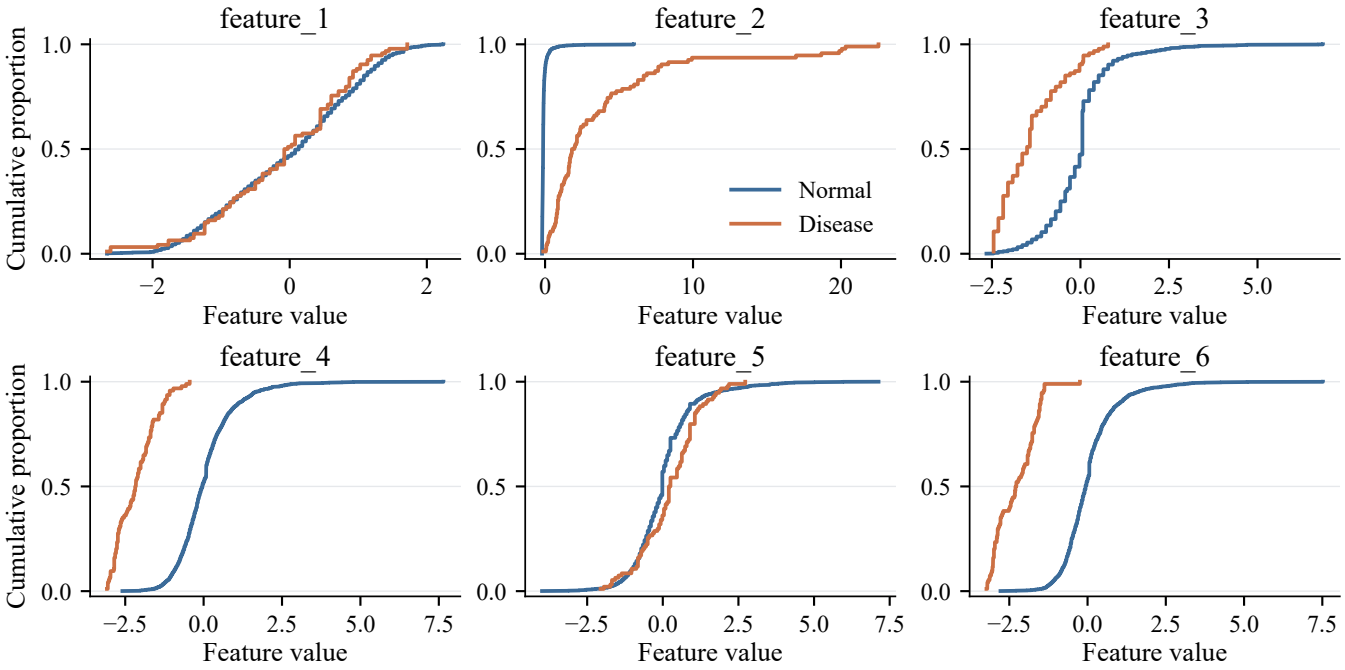


图 2: 测试集正常与患病样本的特征分布

表 3: 独立检测分支与秩融合方法的测试集结果

方法	AUROC	AUPRC	F1	Precision	Recall
Isolation Forest	**0.9848**	0.8932	0.8632	0.8542	**0.8723**
HBOS	0.9821	0.8592	0.8187	0.7980	0.8404
MCD	0.9791	0.8245	0.7923	0.7257	**0.8723**
秩融合	0.9846	**0.9060**	**0.8663**	**0.8710**	0.8617

粗体表示每列最优值，F1、Precision 和 Recall 对应各方法的测试集最佳 F1 阈值

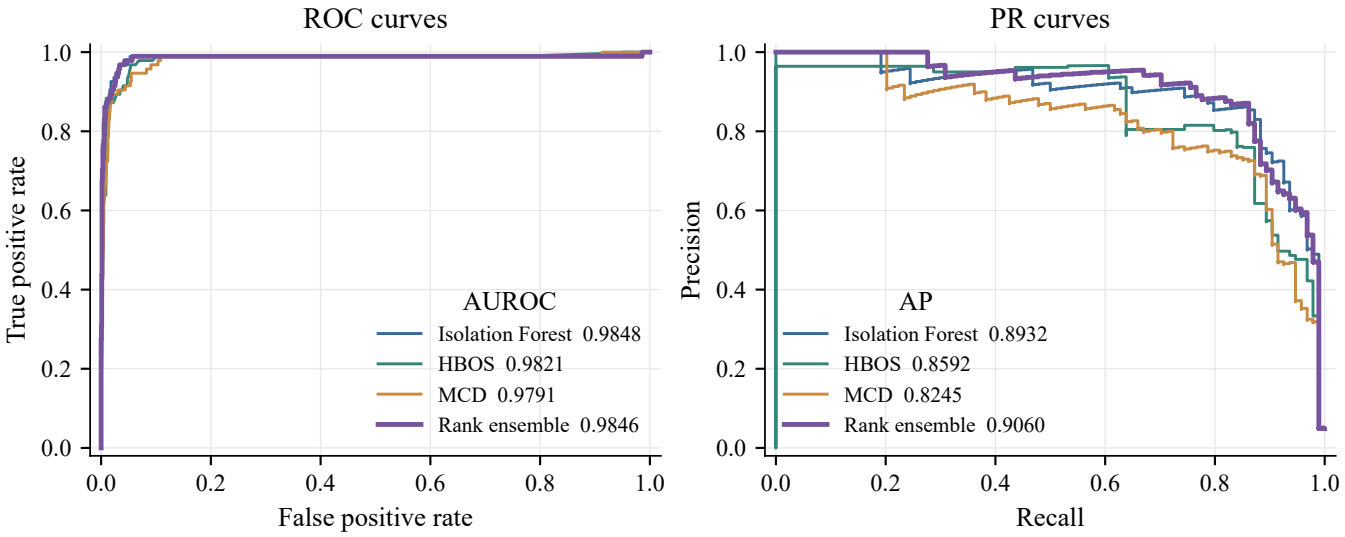


图 3: 独立检测分支与秩融合方法的 ROC 和 PR 曲线

融合后的 AUPRC 提高 0.0128，F1 从 0.8632 提高至 0.8663，精确率从 0.8542 提高至 0.8710。

图 3 展示的是各方法的 ROC 曲线与精确率–召回率曲线。四种方法的 ROC 曲线集中于左上区域，反映了正常与患病样本的排序差异。PR 曲线进一步展示了阈值变化时患病样本的检出比例及对应精确率，融合方法的曲线综合了三个分支的排序信息。

图 4 展示的是正常与患病样本的融合分数分布。两类样本的分数中位数分别为 0.4472 和 0.9727，患病样本的四分位区间为 $[0.9609, 0.9858]$，多数患病记录集中于高分区域。

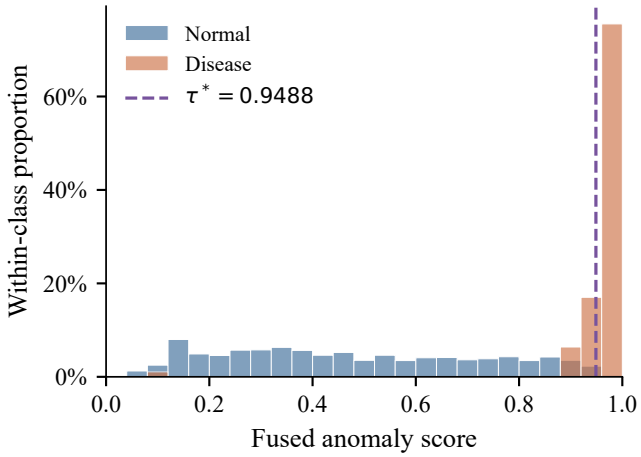


图 4: 正常与患病样本的融合分数分布

图 5 展示的是测试集最佳 F1 阈值 $\tau^* \approx 0.948844$ 下的混淆矩阵。94 个患病样本中识别出 81 个，1,839 个正常样本中正确判断 1,827 个。该阈值下的 F1 为 0.8663，精确率为 0.8710，召回率为 0.8617。

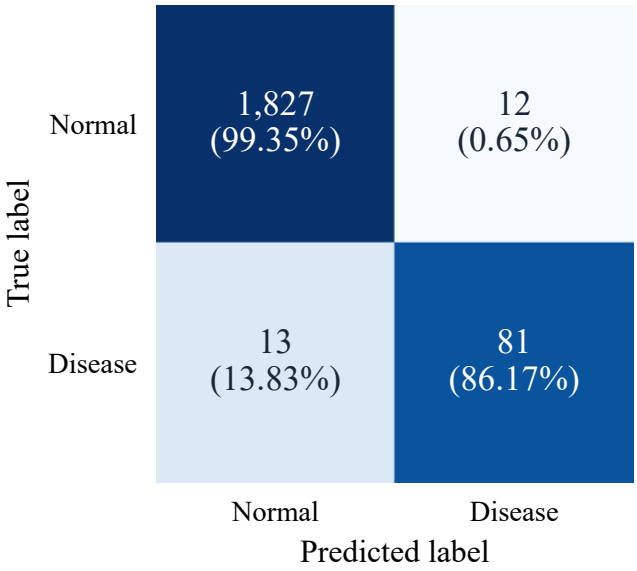


图 5: 测试集最佳 F1 阈值下的混淆矩阵

1.8 小结

多检测器秩融合将随机隔离、边缘密度与稳健距离提供的异常次序整合为统一评分。在给定 Thyroid 数据划分下，融合方法的 AUROC 为 0.9846，AUPRC 为 0.9060，测试集最佳 F1 为 0.8663。相较 Isolation Forest 分支，融合后的 AUPRC 提高 0.0128，精确率提高 0.0168。

参考文献

[1] Markus Goldstein and Andreas Dengel. 2012. Histogram-based Outlier Score (HBOS): A Fast Unsupervised Anomaly Detection Algorithm. In *KI-2012: Poster and Demo Track*, Stefan Wölfl (Ed.). Online, Saarbrücken, Germany, 59–63. https://www.dfki.de/en/web/research/projects-and-publications/publication/6431

[2] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. 2008. Isolation Forest. In *2008 Eighth IEEE International Conference on Data Mining*. IEEE, Pisa, Italy, 413–422. doi:10.1109/ICDM.2008.17

[3] Peter J. Rousseeuw and Katrien Van Driessen. 1999. A Fast Algorithm for the Minimum Covariance Determinant Estimator. *Technometrics* 41, 3 (1999), 212–223. doi:10.1080/00401706.1999.10485670

[4] scikit-learn developers. 2026. Average Precision Score. scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html

[5] Yue Zhao, Zain Nasrullah, and Zheng Li. 2019. PyOD: A Python Toolbox for Scalable Outlier Detection. *Journal of Machine Learning Research* 20, 96 (2019), 1–7. https://jmlr.org/papers/v20/19-011.html